

O que diferencia um tumor maligno de um benigno?

O que 569 exames de câncer de mama revelam, e o que o hospital precisa saber antes de usar esses dados em algoritmos de IA.

Danielli Arçari | Outubro de 2026 | Formação em Engenharia e Análise de Dados MCIO Brasil e Leega Academy

37,3%

dos exames são malignos (212 de 569)

2,1x

maior é a área média das células nos tumores malignos

3,5x

maior é a concavidade do contorno nos tumores malignos

A mensagem em cinco minutos

Dos 569 exames, pouco mais de um terço são malignos. O que separa os dois grupos é o **tamanho** e a **irregularidade do contorno** das células: nos malignos, a área é duas vezes maior e as reentrâncias, mais de três vezes.

Os valores extremos que parecem erros são, em sua maioria, os casos mais graves, e precisam ficar na base. Como muitas medidas repetem a mesma informação, um conjunto menor e bem escolhido tende a ser suficiente para o algoritmo.

Próximo passo: validar essas conclusões com a equipe médica e testá-las na IA do hospital.

O pedido do hospital

Um hospital entregou uma base de exames de câncer de mama e trouxe para a reunião uma pergunta de fundo: **o que esses dados dizem, e eles estão prontos para alimentar os algoritmos de IA da instituição?** Na prática, a equipe pediu cinco respostas:

- 1 Quantos casos são benignos e quantos são malignos?
- 2 Como os valores das medidas se distribuem?
- 3 Existem valores fora do padrão (outliers)? Eles atrapalham a IA?
- 4 Quais medidas realmente importam para identificar um tumor maligno?
- 5 Um painel para os médicos consultarem os dados sem precisar de código.

Os dados

A base é a **Breast Cancer Wisconsin (Diagnostic)**, uma referência pública em estudos de dados de saúde. Cada linha é um exame feito a partir de imagens de células coletadas por punção aspirativa por agulha fina. Além do diagnóstico (benigno ou maligno), cada exame traz 30 medidas que descrevem as células: tamanho (raio, perímetro e área), formato do contorno (concavidade, pontos côncavos e compacidade), textura, suavidade, simetria e dimensão fractal. Cada característica aparece em três versões: a média, o erro padrão e o pior valor encontrado no exame.

Antes da análise: quando os dados não chegam prontos

O exercício não rodou de primeira, e resolver isso foi parte importante do trabalho.

O arquivo de dados que acompanhava a aula **não continha dados**: era o relatório final salvo com a extensão errada. Pelo conteúdo do relatório, identifiquei a base original e conferi que os números batiam: 569 exames, 357 benignos e 212 malignos.


Depois disso, ainda apareceram três obstáculos. O Google Drive converteu o arquivo em planilha e o Python não conseguia lê-lo. Uma coluna vazia, criada por uma vírgula a mais no arquivo, travava os gráficos. E uma atualização da biblioteca Pandas fez o cálculo de correlação deixar de funcionar como na aula. Cada um foi corrigido com um ajuste pontual, sem alterar a lógica do exercício.

No trabalho real, boa parte da análise começa antes do primeiro gráfico: conferir se os dados são o que dizem ser é o que garante que as conclusões se sustentam.

O que os dados mostraram

PERGUNTA 1 | BENIGNOS E MALIGNOS

Quase 4 em cada 10 exames são malignos




Distribuição dos 569 exames por diagnóstico.

Há casos suficientes dos dois tipos para compará-los. Mas existe uma armadilha para a IA: um algoritmo que respondesse "benigno" para todo mundo acertaria 62,7% das vezes e, mesmo assim, não encontraria nenhum câncer. Por isso, um modelo deve ser avaliado principalmente pela quantidade de casos malignos que consegue identificar, e não só pela taxa de acerto geral.

PERGUNTA 2 | DISTRIBUIÇÃO DAS MEDIDAS

A maioria dos exames tem valores baixos, e poucos têm valores muito altos




Distribuição da área média das células. O mesmo padrão aparece na maior parte das medidas.

Na maior parte das medidas, os exames se concentram em valores baixos e uma minoria se estende para valores bem mais altos. Na área média das células, por exemplo, metade dos exames fica abaixo de 551, mas os maiores valores passam de 2.500.

As medidas também estão em escalas muito diferentes: a área chega aos milhares, enquanto a dimensão fractal fica em torno de 0,06. Antes de usar os dados em um algoritmo, é preciso colocá-los na mesma escala, para que os números grandes não pesem mais só por serem grandes.

PERGUNTA 3 | VALORES FORA DO PADRÃO

Os valores fora do padrão não são erros: em sua maioria, são os casos mais graves



Valores fora do padrão (critério do boxplot) nas medidas com mais ocorrências, por diagnóstico.


Quase todas as medidas (29 de 30) têm valores fora do padrão. A primeira reação seria descartá-los como erros, mas os dados contam outra história: nas medidas ligadas ao tamanho das células, **praticamente todos os valores extremos são tumores malignos**. Na área média, são 25 de 25; na área pelo erro padrão, 65 de 65.

Há uma exceção que merece atenção: na suavidade (erro padrão), 26 dos 30 valores extremos são de tumores benignos. Ou seja, nem todo valor fora do padrão significa a mesma coisa, e a decisão não deve ser automática.

Recomendação: não remover os valores extremos antes de alimentar a IA. Eles representam justamente os casos que o algoritmo mais precisa aprender a reconhecer. O ideal é validar com a equipe médica se esses valores são clinicamente plausíveis.

PERGUNTA 4 | MEDIDAS MAIS IMPORTANTES

Tamanho e contorno irregular são os grandes sinais de alerta




Correlação entre as 10 medidas médias. Quanto mais azul, mais as duas medidas sobem juntas. A matriz com as 30 variáveis está no repositório do projeto.

A matriz de correlação mostra quais medidas andam juntas, e traz dois achados.

Muitas medidas dizem a mesma coisa. Raio, perímetro e área estão praticamente 100% relacionados (correlação entre 0,99 e 1,00), o que faz sentido: quando uma célula cresce, as três medidas crescem juntas. Concavidade, pontos côncavos e compacidade formam um segundo grupo muito parecido.

Algumas medidas separam claramente os dois grupos. Comparando a média dos exames malignos com a dos benignos, a diferença fica concreta:



Quantas vezes a média de cada medida é maior nos tumores malignos do que nos benignos.

Nos tumores malignos, a área média das células é de 978, contra 463 nos benignos, e a concavidade é de 0,161, contra 0,046. Ou seja, as células são maiores e têm contornos muito mais irregulares. Já a dimensão fractal é a mesma nos dois grupos e não ajuda a diferenciá-los. A correlação direta com o diagnóstico confirma o quadro: as medidas mais associadas a um tumor maligno são os pontos côncavos (0,79), o perímetro e o raio (0,78).

Recomendação: priorizar as medidas de tamanho e de irregularidade do contorno e, entre as que repetem a mesma informação, manter apenas uma. Medidas sem relação com o diagnóstico podem ser retiradas, desde que isso seja testado no próprio algoritmo.

PERGUNTA 5 | PAINEL PARA OS MÉDICOS

Um painel para explorar os dados sem escrever código

O painel foi gerado com o Sweetviz, uma ferramenta que monta automaticamente um relatório navegável. Para cada medida, ele mostra média, mediana, mínimo, máximo, quartis, desvio padrão, valores ausentes e um gráfico da distribuição, além de um resumo de como as medidas se relacionam. Assim, os médicos podem consultar qualquer variável por conta própria.

Acesse o painel em: [visualização online do painel](#).

Recomendações para o hospital

- 1 **Avaliar a IA pelos casos malignos que ela encontra**, e não só pela taxa de acerto geral, já que as classes são desbalanceadas.
- 2 **Colocar as medidas na mesma escala** antes de treinar qualquer algoritmo.
- 3 **Manter os valores extremos na base** e validar com a equipe médica se são clinicamente plausíveis.
- 4 **Priorizar tamanho e irregularidade do contorno**, mantendo uma medida por grupo redundante e testando no algoritmo a retirada das demais.
- 5 **Validar estas conclusões com a equipe médica** antes de levá-las para a IA do hospital.

Sobre o projeto

Projeto desenvolvido no Módulo 4 (visualização de dados com Python) da formação em Engenharia e Análise de Dados da MCIO Brasil, associação sem fins lucrativos que promove a inclusão de mulheres na tecnologia, em parceria com a Leega Academy.

Ferramentas: Python, Google Colab, Pandas, NumPy, Seaborn, Matplotlib, Scikit-learn e Sweetviz.

Código e dados: github.com/danielli-arcari/analiseComSweetViz_hospital

Contato: [linkedin.com/in/danielli-arcari](https://www.linkedin.com/in/danielli-arcari) | danielliarcari.vercel.app

Exercício de análise exploratória para fins de estudo. Os resultados não têm finalidade diagnóstica.